

03-12 Лекция: эволюция трансформеров и LLM, внимание, токены, температура и сравнение моделей

Дата и время: 2026-03-12 09:11:42

Локация: [Вставить локацию]

Инструктор: [Вставить имя]

Резюме

Лекция раскрывает эволюцию и принципы работы современных больших языковых моделей (LLM) на базе трансформеров: от мотивации машинного перевода и векторных представлений смысла (эмбеддингов) до механизма внимания, контекстного окна и генерации следующего токена. Показано, как переход от простых предикторов (T9, ранние подсказки клавиатур) к архитектуре трансформеров обеспечил качественный скачок в переводе (особенно после 2018 года), понимании контекста и способности моделей решать широкий спектр задач через предсказание следующего слова. Обсуждается роль токенизации, вероятностных распределений и параметров выборки (температура, top-p) в управлении креативностью и точностью, влияние ранних выборов токенов на дальнейшее продолжение, а также использование системных инструкций для регуляции формата и стиля ответов. Демонстрируются практические кейсы: семантические операции над эмбеддингами, разбор полисемии через контекст и внимание, сравнение моделей (Gemini 2.5, Qwen-3, GPT-3/3.5/4/4.1), работа с длинным контекстом, и применение LLM к олимпиадным задачам «Кенгуру».

Ключевые пункты знаний

1. Эволюция языковых моделей и роль перевода

- Машинный перевод потребовал извлечения смысла и его числового кодирования; пословный перевод несостоятелен из-за морфологии и контекстной неоднозначности.

- Скачок качества перевода в 2018–2020 связан с трансформерами, ростом данных и мощности, предобучением на больших корпусах.
- Переход от распознавания речи по ключевым словам к пониманию текста и контекста.

2. Векторные представления (эмбеддинги) и смысловые операции

- Смысл слов кодируется векторами в многомерном пространстве (десятки тысяч измерений), что позволяет применять математические операции.
- Смысловые манипуляции через сложение/вычитание векторов приводят к ожидаемым ассоциациям, но результат попадает в «окрестность» целевой точки, что объясняет вариативность.
- Полисемия требует контекстной дисамбигуации: одно слово соответствует разным областям пространства в зависимости от окружения.

3. Контекст и механизм внимания (Attention Is All You Need)

- Внимание вычисляет степени связи между всеми парами токенов, уточняя представления слов в контексте и снимая неоднозначности (например, bank).
- Трансформер реализует внимание; «Т» в GPT означает «Transformer». Эти принципы лежат в основе понимания и генерации текста в LLM.

4. Предсказание следующего слова как универсальная парадигма

- Генерация сводится к предсказанию следующего токена с учетом контекста; через линейное представление задач (включая тесты с вариантами) модель решает широкий спектр задач.
- «Магия» чат-моделей проявилась, когда предсказание стало опираться на глубокие контекстные связи, а не на поверхностную статистику.

5. Сравнение с ранними предикторами (T9 и автоподстановки)

- Ранние системы опирались на частотную статистику без внимания и глубокого контекста, производя бессвязные тексты при последовательном выборе подсказок.
- Современные LLM удерживают связность и смысл за счет внимания и контекстных представлений.

6. Контекстное окно и токены

- Контекстное окно — объем текста, доступный модели; у ряда современных моделей оно достигает порядка миллиона токенов, что позволяет обрабатывать большие документы целиком.

- Токен — базовая единица предсказания (часть слова/слово); токенизация балансирует между размером словаря и семантической эффективностью.
- Эволюция токенизаторов (GPT-3 → 3.5/4) сократила число токенов для русского текста почти вдвое, улучшив эффективность и качество.

7. Механика генерации: распределения, температура и выборка

- На каждом шаге модель выдает распределение вероятностей по словарю; выбор всегда вероятностный, чтобы избежать детерминизма и повысить разнообразие.
- Температура управляет «плоскостью» распределения: низкая — стабильность и точность (арифметика, классификация), высокая — креативность и риск галлюцинаций.
- Дополнительные методы (top-p/nucleus sampling, отсечение низких вероятностей) ограничивают пространство выбора.
- Ранние ошибки выбора токенов каскадно влияют на длинные продолжения, что делает настройку параметров критичной.

8. Управление поведением: System Instruction и конфигурация под задачу

- Системные инструкции задают формат и стиль ответа («одним словом», «тремя словами» и т.д.) и в сочетании с температурой формируют итоговый вывод.
- Дефолтные настройки удобны для типовых запросов, но для сложных многошаговых задач требуется ручная конфигурация параметров и контроль человеком.

9. Обучение, данные и межъязыковое обобщение

- Предобучение подбирает параметры по большим корпусам текстов; модель отражает статистику данных, а не статичную «карту» правил.
- Качество зависит от корпуса и языка; при достаточной сложности возникает перенос понятий между языками.
- Обсуждается использование открытых интернет-данных, транскриптов, книг; качество напрямую связано с охватом и чистотой данных.

10. Сравнение моделей и практические демонстрации

- Gemini 2.5 демонстрирует более развернутые рассуждения и правильные решения; Qwen-3 чаще ошибается на шагах рассуждения.
- GPT-3 испытывал трудности с русским; GPT-3.5/4 улучшили токенизацию и качество; GPT-4.1 при высокой температуре может выдавать

нерелевантные продолжения.

- Показаны веб-инструменты для визуализации токенизации и распределений, а также Google iStudio для экспериментов с температурой и параметрами выборки.

11. Применение к задачам «Кенгуру»

- Модели решают текстовые формулировки задач, включая геометрию (отношение площадей при изменении основания/высоты), что иллюстрирует силу контекстного предсказания и пошаговых рассуждений.
- Сравнение разных моделей на одних и тех же задачах позволяет оценивать точность и устойчивость к ошибкам.

Вопросы

- [Insert Question/Confusion]

Задания

- [] Подготовить конспект по эмбедингам: объяснить пользу высокоразмерных пространств и привести 2–3 примера векторных операций.
- [] Разобрать три примера полисемии слова «модель» и выделить контекстные маркеры, снимающие неоднозначность.
- [] Изучить «Attention Is All You Need» и кратко описать вычисление весов внимания и их влияние на представления.
- [] Сравнить ранние голосовые интерфейсы на ключевых словах с трансформерами по работе с контекстом.
- [] Объяснить, как предсказание следующего слова позволяет решать тесты с вариантами; структурировать промпт и формат вывода.
- [] Практически сравнить автоподстановки смартфона и LLM, оценив связность результатов.
- [] Подготовить набор задач «Кенгуру», протестировать несколько моделей и сравнить точность/объяснения.
- [] Экспериментально проверить влияние размера контекста на качество решения задач.
- [] Провести эксперименты с температурой (низкая для точных задач, высокая для творческих), зафиксировать различия.
- [] Визуализировать токенизацию русских фраз у разных моделей/версий токенизаторов.

- [] Смоделировать продолжение фразы «... по имени ...» и сравнить топ-5 имен при разных температурах.
- [] Оценить влияние ранних «плохих» токенов на длинную генерацию (сравнить высокую и низкую температуры).
- [] Создать и протестировать System Instruction (формат ответа), оценить влияние на результат.
- [] Настроить параметры выборки (например, top-p до совокупной вероятности 90%) и оценить качество/разнообразие.
- [] Для генерации кода подобрать температуру около низкой, избежав излишней шаблонности; обосновать выбор.