

03-30 Создание и обучение AI-агента для миграции данных и разработки фронтенда

Создание и обучение AI-агента для миграции данных и разработки фронтенда

Проект: ETL + Web UI

Создание и обучение AI-агента для миграции данных

Автоматизация извлечения, нормализации и визуализации данных студентов

Архитектура Агента

**Двухуровневая Память**

Долгосрочные правила (.md) и краткие логи текущих сессий для контекста.

**Набор Навыков (Skills)**

Модули Extract, Load, Transform и Reflect для итеративного самообучения.

РАБОЧИЙ ЦИКЛ MVP

✓ Проверка памяти

✓ Создание сессионного лога

✓ Выполнение шага ETL

✓ Фиксация договоренностей

**ИТОГ МИГРАЦИИ TETCOL DB**

234

Студента

11915

ГруппНаправлений

Стратегия Трансформации

Слой Extract (Сырые данные)

Выгрузка 21 вкладки Google Sheets "как есть" в CSV для сохранения исходной структуры.



Слой Transform (Нормализация)

Маппинг на сущности: Люди, Группы, Специальности. Игнорирование финансовых реестров.

Бизнес-правила валидации

**Стоп-фактор:** Запрос уточнения при неясных датах групп.

**Группировка:** Разделение по временным зазорам и пустым строкам.

**Игнор-лист:** Исключение листов «Украина», «Бангладеш», «ПАГа».

**Приоритет:** Импорт только при 100% уверенности в валидности.

**Визуализация**

Интерфейс на **shadcn/ui**: дэшборд, таблицы студентов и карточки групп.

React

Tailwind

Raspberry Pi

**Безопасность**

 БД отдельно на VPS в EC

 GitHub: только код и схемы

БЛИЖАЙШИЕ ЗАДАЧИ

☐ Перенос skills в корень

☐ Скрипт импорта Google Sheets

☐ Развертывание Web UI

Статус: В работе

Начальная постановка задачи и создание структуры проекта

Проект стартует с четкой цели: создать AI-агента для выполнения ETL-операций — извлечения данных из CSV-файлов, их нормализации и загрузки в базу SQLite. Отмечается важность использования профессиональной терминологии (“ETL”), чтобы лучше выстроить результат и коммуникацию.

Формулируются ключевые требования к агенту:

- Адаптивность — подстраиваться под работу пользователя и контекст задач.
- Память — фиксировать важную информацию в отдельном файле “долгосрочная память” и вести краткие журналы сессий.
- Наборы “навыков” (skills) по операциям Extract, Load, Transform, Reflect.

Первая генерация структуры проекта агентом выходит избыточной: создаются папки для разных агентов и множество файлов для отдельных операций, что повышает риски путаницы и “расщепления правды”. В ответ принимается курс на упрощение для MVP: минимизировать число файлов, оставить две области памяти (долгосрочную и сессионные логи), и работать с одним агентом в одной корневой папке проекта.

Сформированный стартовый каркас включает:

- Базовую инструкцию и главные файлы с правилами работы.
- Долгосрочную и сессионную логику, отдельную зону агента.
- Структуру, разделенную на слои, и служебные зоны для данных.
- Папки: data (Incoming, Process, Rejected), DB, logs, sessions, skills (Extract, Load, Transform, Reflect), а также Extract Templates.

Дополнительно фиксируется рабочий цикл агента: проверка памяти (short/long-term), понимание текущей задачи, создание краткого лога, выполнение шага, при появлении устойчивых договоренностей — обновление долгосрочной памяти, запись краткого итога сессии.

Итог начального этапа: структура готова для одного агента, содержимое подпапки “agent” требуется перенести в корневую директорию. Далее планируется итеративная адаптация.

Процесс импорта данных: от простого CSV к сложной Google-таблице

Первые попытки импорта из одного CSV завершаются базовым успехом (рабочий скрипт, нормализованный CSV, 45 непустых строк), но выявляются ошибки и случаи неполных данных (например: Надежда Мерчан — отсутствует дата; Мама Татьяна — нет ID-кода; Мария Людшинская — дата восстановлена

из диапазона Location Narrow, но нет программных сведений).

Устанавливается устойчивое правило: перед импортом агент должен собрать выявленные ошибки, задать короткие уточняющие вопросы пользователю и приступать к загрузке только после подтверждения.

Проект расширяется: вместо одного CSV агенту дают ссылку на Google Sheets с множеством вкладок. Агент анализирует документ и обнаруживает 21 вкладку неоднородной структуры, где:

- “Гуляют” колонки: заголовки присутствуют не везде, одно и то же поле называется по-разному (“ИК”, “ИК маленькая”, “его код”, “КК номер”, “результат”, “примечание”).
- Даты представлены в нескольких форматах, встречаются диапазонные и частичные значения.
- На вкладках смешаны оплаты, данные о студентах, потоки, лиды — единая схема отсутствует.

В результате принимается двухслойная стратегия импорта:

- Слой Extract: выгрузка листов “как есть”, предпочтительно в CSV по именам вкладок (через XLS типизация значений хуже).
- Слой Transform: нормализация в таблицы: люди (студенты), курсы, lead entities, entries, invoice entries.

Приоритизация данных на текущем этапе: импортировать только студентов, их данные, специальности (например, КОК) и группы; остальные сущности временно игнорировать. Отдельно фиксируется необходимость четкой связности данных, чтобы последующая работа (вопросы к данным, аналитика) была возможна.

По итогам анализа вкладок:

- Есть нестандартные листы: «Украина», «День ООД», «Скрытая Бангладеш», финансовый реестр «АРВА», пустой лист «ПАГА» — их планируется игнорировать.
- Готовность к импорту частичная: источник Google Sheets читается, вкладки собираются, модель “студенты — группы — специальности” понятна. Не до конца определена логика выделения групп: встречаются вкладки и строки, где группы не определяются надежно; иногда группы разделяются пустыми строками и/или выделяются желтым цветом.

Операционный конвейер уточняется:

- Агент скачивает Google-таблицу, преобразует вкладки в набор CSV.

- Отбирает вкладки, касающиеся специальностей, и обрабатывает каждую вкладку в отдельном проходе.
- Если наблюдает неясность, задает вопросы пользователю.
- После успешного импорта файл перемещается в “импортированный”, а данные остаются в базе.
- Нельзя импортировать данные без “полной стопроцентной уверенности” в их валидности.

Обучение агента через диалог: обработка исключений и валидация данных

Ключевой этап — интерактивное обучение агента через диалог, где фиксируются бизнес-правила для обработки исключений. Агент подтверждает неоднородность 21 вкладки, перепады в названиях колонок, множественные форматы дат и смешение сущностей. Выбран подход “вопросы перед импортом” и послойный импорт.

Фиксируются конкретные правила:

- Импортируем только студентов, специальности (например, Холдэя, Флористика, Бармен) и группы; остальные сущности (например, “затраты, суммы, остатки”) игнорируем.
- Обработка идет вкладка за вкладкой.
- Игнорировать листы «Украина», «Бангладеш», «День ОД», «Армии», «Мастер-класса», «ПАГа».
- Если специальность в строке пустая, но вкладка профильная — брать специальность из имени вкладки.
- Строки внутри профильной вкладки без дат импортировать без дат.
- Определение групп:
 - Если даты сильно отличаются — это разные группы.
 - Пример: если одна группа с 3 марта по 2 мая, а другая с 12 мая по 22 марта — это две разные группы.
 - В одном блоке возможна смесь дат 24–25-го года, что требует разделения.
- Блокер перед импортом: строки без дат внутри блока, уже разбитого по датам на несколько групп. Решение:

- Импортировать эти строки, но не включать их в группы (если по наиболее распространенным датам группировка не определяется надежно).
- Агент запрашивает конкретные даты для отдельных студентов (например, Нелли и Никитенко Наталья) — принято правило “взять даты из курса” при наличии неопределенности.

На уровне процесса:

- Агент вносит сценарий экспорта вкладок Google Sheets в CSV и фильтрации в долгосрочную память.
- Останавливается до импорта, фиксируя оставшиеся два блока и запрашивая уточнения.
- После подтверждений импорт выполняется: база tetcol DB создана, сценарий импорта сохранен.
- Итоги импорта: 15 специальностей, 119 групп, 234 студента; 213 студентов привязаны к группам, 21 студент импортирован без групп.

Успешная миграция и создание веб-интерфейса

После серии уточнений и проверки валидности агент успешно мигрирует данные в SQLite (tetcol DB) и фиксирует сценарий импорта. Акцент делается на том, что такой агент существенно снижает риски потерь и несоответствий при сложных миграциях.

Следующий шаг — разработка фронтенда для визуализации и интерактивной работы с данными, с использованием библиотеки компонентов shadcn/ui. Описывается ожидаемый UI: дэшборд с сайдбаром, таблицами, карточками, лаконичным современным дизайном. Фронтенд позволяет просматривать студентов, группы и их состав (пример: Николе Шевченко).

Отмечаются технические соображения:

- При изменениях схемы данных нужна полноценная миграция, включающая алгоритмы преобразования текущих записей.
- Возможна обратная совместимость: изменять только базу данных, не затрагивая код приложения, если архитектура это позволяет.
- При планируемом развертывании на мини-компьютере (Raspberry Pi) потребуется аутентификация для защиты данных в локальной сети.

Обсуждение GDPR и дальнейшие шаги

Поднимается вопрос соответствия GDPR при хранении клиентских данных на внешних платформах (GitHub, Google Drive). Важно: сам по себе git push или использование Google Drive не означает автоматического нарушения GDPR. Передача данных за пределы ЕС допускается по Adequacy Decision или по Safeguard (ESSC); по состоянию на 30-е марта решение по Data Privacy Framework остается в силе.

Ключевые риски:

- Главный риск — пуш реальной клиентской базы в публичный репозиторий.
- В приватном репозитории GitHub данные по умолчанию хранятся в США; выбор региона доступен в GitHub Enterprise Cloud.
- Google Workspace платный сам по себе не нарушает GDPR; Google указывает, что GDPR не требует хранить данные только в ЕС. Однако Data Regions покрывают не все данные, часть информации может находиться вне ЕС.
- Риск штрафов зависит от типов данных, наличия договоренностей с провайдерами (DPA/DPS) и уведомлений субъектов.

Принято решение: разделить хранение — база данных (клиентские данные) отдельно в ЕС, код и схема агента — отдельно (можно хранить в GitHub). Рассматриваются варианты развертывания базы: VPS и облачные решения. Отмечается необходимость резервного копирования (бэкапы), иначе возможна потеря клиентов при отказе VPS. Обсуждается перенос базы в клиент-серверную архитектуру (например, Cloudflare), где операции выполняются по ключам и паролям; указываются возможности большого бесплатного лимита и инфраструктурной поддержки.

Технические ограничения:

- При развертывании на Raspberry Pi требуется аутентификация.
- При параллельном редактировании файла SQLite (например, Ольга и Татьяна одновременно) возможны конфликты, что усиливает аргументацию за клиент-серверную базу и отказ от хранения БД в GitHub.

Action Items

@Speaker 1

- [] Создать структуру папок проекта и файл [agents.md](#) - [TBD]
- [] Сообщить агенту, что папка будет для единственного агента, и все хранить в ней - [TBD]

- [] Сообщить агенту, что нужны skills для каждой операции - [TBD]
- [] Выстроить петлю обратной связи: после каждой сессии снимать обратную связь, обобщать и сохранять - [TBD]
- [] Переместить содержимое из папки agent в корневую папку проекта - [TBD]
- [] Сохранить данные (CSV) в входящую папку данных ("Incoming") - [TBD]
- [] Выстроить петлю обучения: чтобы агент в процессе работы сам себя настраивал (сбор обратной связи, обобщение, сохранение) - [TBD]
- [] Перенести папку skills из подпапки agent в корень проекта - [TBD]
- [] Загрузить в проект данные, которые предоставила Ольга - [TBD]
- [] Создать агента (инициализация) - [TBD]
- [] Выполнить первый импорт - [TBD]
- [] Собрать общие данные о компании TetCol, сохранить профиль и добавить ссылку на него в [Agents.md](#) - [TBD]
- [] Попробовать выполнить первый импорт (после подготовки профиля и документации) - [TBD]
- [] Запустить скрипт на Python для импорта - [TBD]
- [] Перейти к правке файлов: добавить воспроизводимый скрипт импорта - [TBD]
- [] После выполнения скрипта спросить агента о затруднениях и сохранить ответы в память (short/long-term) - [TBD]
- [] Перед каждым импортом: собрать ошибки/неясности, задать короткие вопросы пользователю, импортировать только после подтверждения - [TBD]
- [] Удалить базу данных и провести импорт заново по новым правилам (в новой сессии) - [TBD]
- [] Предоставить агенту ссылку на Google Sheets, проанализировать вкладки и сформировать стратегию импорта - [TBD]
- [] Записать правило: импортируем только студентов, их данные, специальности (например, КОК) и группы - [TBD]
- [] Остальными данными пока пренебречь - [TBD]
- [] Провести дабл-чек готовности к импорту - [TBD]
- [] Указать агенту, что группы разделяются пустой строкой (использовать как эвристику) - [TBD]
- [] Если есть вопросы по импорту, задавать их до загрузки - [TBD]
- [] Игнорировать листы, которые явно не подходят (нестандартные лидовые/финансовые/пустые) - [TBD]
- [] Игнорировать конкретные листы: «Украина», «Бангладеш», «День ОД», «Армии», «Мастер-класса», «ПАГа» - [TBD]

- [] Создать фронтенд для визуализации базы данных с использованием shadcn/ui (таблицы, карточки, дэшборд) - [TBD]
- [] Запустить новую сессию для создания фронтенда - [TBD]
- [] Рассмотреть варианты хостинга: разделить базу (в EC) и логику агента (код) - [TBD]
- [] Продумать, как разместить базу в VPS (с учетом резервного копирования) - [TBD]
- [] Запустить папку проекта локально, стянуть с GitHub и запустить фронтенд (без файла БД в репозитории) - [TBD]
- [] Сохранить код и схему агента в приватном репозитории GitHub (без клиентских данных) - [TBD]

@Speaker 2

- [] Агент должен был написать план: собрать единый план действий - [TBD]
- [] Запустить базу данных на GitHub (требует пересмотра в контексте GDPR; предпочтительно заменить на пуш только кода/схемы) - [TBD]

@Speaker 5

- [] Отслеживать уведомления агента: список работающих/неработающих лидов и статусы ("горячие", "теплые", "на потом") — операционное принятие и обработка - [TBD]