

04-02 Рабочая встреча: Агрегация и обогащение базы ресторанов из Bolt, Wolt, OSM, RIG и Agri; матчнук по регкодам, архитектура агентов и интеграция с CRM

Информация о встрече

Дата: 2026-04-02 10:36:50

Локация: [Вставить локацию]

Участники: [Speaker 1] [Speaker 2] [Speaker 3] [Speaker 4] [Speaker 5]
[Speaker 6]

Заметки встречи

- Тема: Сбор и обогащение базы ресторанов из внешних источников (Bolt Food, Wolt, OSM, RIG, Agri)
 - Цель: масштабировать уже реализованный парсинг Bolt Food на Wolt и OSM; покрыть рестораны вне экосистем доставок (локальные столовые и т. п.).
 - Основные поля интереса: название бизнеса, регистрационный код (OU/AS/рег. код), телефон, сайт, адрес, координаты; по Wolt — статусы доставки, merchant/business/DSA ID; по Bolt — юрлицо, регистрационный код, billing address.
 - В OSM выгружено 1500–2500 объектов по Эстонии; около 10% имеют поле «фирма», телефоны часто доступны; попадают и объекты без доставки (АЗС/перекус), часть может быть целевым сегментом.
 - Мишленовские рестораны часто не работают с доставкой; учитывать при целевом сегментировании.
- Тема: Технический подход к сбору и ограничения
 - Использование краулеров/агентов и управляемого браузера («Кодекс») для автоматизированного сбора с публичных страниц и

- прямого доступа к внутренним API (миновать рендер и забирать структурированные данные).
- Обсуждение противодействий (CAPTCHA, Cloudflare) и поиск законных путей; акцент на работе только с открытой информацией без взлома.
- При массовых запросах к API Bolt возникает блокировка при ~1000 запросах подряд; решение — дискретизация запросов и паузы, сбор в фоне за ~1 час.
- Ограничения VPS (2 ядра, 2 ГБ ОЗУ, без GUI) могут делать запуск браузера нестабильным; тяжелые операции — локально/в «Кодексе».
- Тема: Результаты текущего сбора
 - Bolt Food (Эстония): собрано 787 объектов (рестораны и магазины), расширенные юрданные из API; создан веб-интерфейс Restaurant Explore для SQLite (адрес, координаты, контакты, юрлицо, рег. код, billing address, дата сбора).
 - Wolt (Эстония): ~1000 объектов по стране, ~712 по Таллину; для каждого — адрес, телефон, координаты, статусы доставки, merchant/business/DSA ID; возможна выгрузка меню; публичный список не всегда возвращает рег. номер, требуется исследование других endpoints.
 - OSM: первичная выгрузка и оценка полноты полей (сайт/телефон), пригодность для доп. покрытия.
- Тема: Организация проекта, репозиторий и агентная архитектура
 - Единица — папка агента, синхронизируемая с GitHub; рекомендуется организация и репозиторий, ветки для фич (например, Google Maps), пул-реквесты и код-ревью; [Agents.md/README](https://agents.md/README) с задачами, рутиной, расписанием.
 - SQLite как локальное хранилище подходит на старте, но чревато конфликтами при параллельной работе; в перспективе — централизованная БД.
 - «Опенклоп/OpenClaw» как оркестратор для регулярного запуска готовых скриптов, отчетов о новых объектах и экшенов; баланс между полной автоматизацией и контролируемой разработкой в «Кодексе».
- Тема: MVP Aggregation Agent и логика слияния
 - MVP собран: строит Unified Leaks SQL из RIG, Agri, Bolt, Wolt, OSM; пишет сводку в Unified Summary; поднимает объединенные представления (views) без физического слияния.
 - Company-level match: точный матч по регистрационному коду как единственному надежному идентификатору; при наличии рег. номера

- не использовать название как второй критерий.
- Для записей без регистрационного кода создаются канонические компании без автоматического слияния.
- Venue/Establishment-level: консервативный матч по рег. коду компании + нормализованному адресу и вариациям названий («Кафе Ромашка» vs «Ромашка кафе»); при разных адресах точки не склеиваются.
- Тема: Качество данных, человеческий фактор и промпт-инжиниринг
 - Данные вводятся людьми, встречаются ошибки и неполнота (например, отсутствие AS/OU в названии); обязательна выборочная проверка (по 5 примеров из каждого источника с указанием полученных полей).
 - Уточнение: если набор содержит рег. номер, он должен матчиться с регистром в подавляющем большинстве случаев; иначе ошибка логики.
 - Принцип human-in-the-loop: агент может закрыть до 95% задач при правильных правилах, остаток требует ручной проверки и корректировок.
 - Точная спецификация ТЗ и явные правила мэппинга по уникальным идентификаторам повышают качество; избегать избыточных условий и жестких комбинаций критериев.
 - Практика итеративных проб (10–15 минут на гипотезу) и корректировок по результатам; роль промпт-инженера — правильная подача входных данных и обработка краевых случаев.
- Тема: Обзор источников регистров и первичная аналитика
 - RIG: ~6500 компаний с EMTAK, ~11000 строк контактов; 6500 email, 3700 телефонов, 372 сайта; ключи — юрлицо, рег. код, статус, регион, EMTAK, контакты.
 - Agri: ~6000 компаний, 1500 с approve; категории (мясо, молоко, рыба, доставка и т. п.).
 - Публичные данные по общепиту: ~4000 компаний, ~6000 площадок; ~658 с разрешениями.
 - Проблема фильтров: RIG с фильтром по основному MТАК 56 отсекает фирмы вне категории (цветы, ритейл), что снижает пересечения; рекомендация — учитывать все коды компании или вести параллельную базу RIG без фильтра 56.
- Тема: Текущие пересечения и вопросы к точности
 - Примеры: Agri-BoltFood ~350 общих ($\approx 5\%$ Agri, $\approx 76\%$ BoltFood); 92% компаний Wolt присутствуют в RIG.

- Bolt: 787 заведений, 611 с рег. кодом, ~150 в «проблемной» зоне; требуется проверить, как ранее считались совпадения (по имени или по рег. коду).
- Запрос на примеры кейсов, где сущность есть в Wolt, но нет в RIG; анализ причин.
- Тема: Бизнес-контекст и лидогенерация в CRM
 - Цель: ежедневная поставка в CRM ~20 новых релевантных лидов (~90% релевантности) с максимально заполненными полями; холодные рассылки и дозапрос недостающих данных.
 - Практическая ценность: даже грубая база (например, 3000 потенциальных клиентов с контактами) повышает эффективность по сравнению с ручным парсингом.
 - Интеграция с CRM: «прокладка» между агентом и CRM для запросного доступа (проверка кода, фильтрация) без полного доступа; согласование с обслуживающей фирмой.
 - Дискуссия по выравниванию под Salesforce: сущности и корректная миграция важнее имен полей на старте; минимальный набор полей для фронтенда/предпросмотра отделен от полного набора в базе.
 - Логистика: продукт не портится; частоты заборов по регионам позволяют работать с удаленными точками (Харью 3–4 раза в неделю, Тарту еженедельно и т. д.).
- Тема: Правовые рамки и безопасность
 - Необходимо проверить законность использования внутренних API и хранения/обработки контактных данных; документировать процесс.
 - Требования безопасности и доступов для «прокладки» к CRM: владение, размещение, аудит и логирование запросов.

Следующие шаги

- [] Отфильтровать из выгрузок Bolt/Wolt нецелевые объекты (магазины и пр.), оставить именно рестораны; разработать классификаторы категорий (кафе, ресторан, кейтеринг, магазин).
- [] Определить и зафиксировать список уникальных идентификаторов для мэппинга (регистрационный код как основной на Company Level); исключить использование названия как второго критерия при наличии рег. номера.
- [] Снять ограничение в RIG на «основной» MTAK 56: учитывать все коды компании; подготовить отдельную базу RIG без фильтра 56 для обогащения.

- [] Сопоставить записи по координатам, адресам и названиям на уровне Venue для удаления дублей; зафиксировать «консервативный Established Level Match» и терминологию («канонические» vs «исходные»).
- [] Объединить данные Bolt, Wolt, OSM, RIG, Agri в единую базу с согласованной схемой: таблица компаний (мастер), таблица точек (venues), таблица связей «компания–точка»; в перспективе — таблица людей и связей.
- [] Настроить дискретизацию запросов к API Bolt/Wolt, чтобы исключить блокировки; скрипты устойчивой загрузки и ретраи.
- [] Исследовать API Wolt (карточки ресторана/меню) на наличие регистрационных данных; задокументировать использованные endpoints.
- [] Провести быстрый эксперимент мэппинга по уникальным полям и оценить результат; запросить по 5 примеров записей из каждого датасета для проверки качества и логики матчинга.
- [] Реализовать многоступенчатое обогащение: дешевые проверки (телефон/e-mail/сайт/ключевые фразы) → поиск маркеров OU/AS/рег. кода на страницах → LLM только для «хвостов»; оценить бюджет LLM и утвердить лимиты.
- [] Настроить экспорт лидов в CRM с ежедневной выдачей ~20 новых релевантных контактов; определить формат интеграции (API, де-дубликация, валидация) и минимальный набор полей.
- [] Подготовить файл документации агента ([Agents.md/README](#)) с задачами, рутиной, расписанием; создать папку «Aggregation Agent» с регламентом регулярных обновлений и runbook процесса слияния.
- [] Проанализировать схемы 5 источников: сопоставить поля, привести даты и форматы к единому стандарту; определить критерии матчинга и порядок разрешения конфликтов.
- [] Настроить процесс регулярного обновления данных (GoatFoot/RIK/Agri/Bolt/Wolt/OSM): расписание, SLA, мониторинг ошибок, откат изменений; запланировать режим ежедневного мониторинга новых регистраций.
- [] Проверить юридические рамки использования внутренних API и хранения персональных данных; оформить политику и требования безопасности.
- [] Подготовить отчет: таблица пересечений по источникам с процентами, долей мульти-источников; 5 примеров кейсов, где сущность есть в Wolt/Bolt, но отсутствует в RIG, с анализом причин.
- [] Определить минимальный фронтенд-набор полей для предпросмотра; проверить возможность добавления МКР/КМКР на этапе обогащения.

Вопросы и рекомендации ИИ

1. Не определены четкие критерии фильтрации «не-ресторанов» и правил де-дубликации; требуется согласованный список.
2. Не зафиксированы юридические рамки использования внутренних API и обработки контактов; нужна политика комплаенса.
3. Нет финального описания схемы объединенной базы (поля, типы, связи) и формата отчетности/экспорта в CRM.
4. Не установлены SLA и расписание регулярного сбора/обновления (частота, мониторинг ошибок, ретраи).
5. Не согласованы целевые сегменты (например, исключение мишленовских) и план последующего контакта.
6. Не определены источники и методы инкрементального обнаружения новых объектов помимо Bolt/Wolt/OSM, а также их приоритеты.
7. Нет решения по конфликтам данных при параллельной работе с SQLite; нужен план перехода на централизованную БД.
8. Не утвержден бюджет и лимиты использования LLM для первичного и инкрементальных прогонов.
9. Не описан механизм автоматической интеграции с CRM (формат, де-дубликация, валидация, частота).
10. Не подтверждено, какие endpoints Wolt возвращают регистрационный номер; требуется аудит API.
11. Не определены критерии «активности» компании (баланс, отчеты) и пороги для разных кейсов.
12. Нет метрик качества слияния (целевой процент матчей по компаниям/заведениям, допустимая ошибка) и регламента ревью выборов.
13. Не назначены ответственные за промпт-инжиниринг, анализ схем и подготовку карты соответствий.
14. Требуются четкие правила обработки краевых случаев ($\approx 5\%$) и безопасной валидации.
15. Не зафиксирован минимальный набор полей и конвенции типов для интеграции с Salesforce, чтобы избежать переработок.

16. Не описаны требования безопасности и доступов для «прокладки» к CRM (владение, размещение, аудит, логирование).