

05-22 Встреча: Технологии STT/TTS, голосовые ассистенты и интеграция с телефонией

Информация о встрече

Дата: 2026-05-22 11:57:23

Место: [Вставьте местоположение]

Участники: [Speaker 1], [Speaker 2], [Speaker 3], [Speaker 4], [Speaker 5], [Speaker 6], [Speaker 7], [Speaker 8], [Speaker 9], [Speaker 10]

Заметки о встрече

Обзор технологий STT, TTS и проблемы задержки

- **Определения:** Участники обсудили разницу между STT (Speech-to-Text, распознавание речи) и TTS (Text-to-Speech, синтез речи).
- **Инструменты для STT:** Упомянут DeepGram (модель Nova 3 для русского языка) и бесплатная модель от Тартуского университета для эстонского.
- **Сложности TTS:** Генерация качественной речи сложна, требует ресурсов и сталкивается с проблемами в передаче эмоций, склонений и озвучивании числительных.
- **Спектр TTS-моделей:** Обсуждались разные модели: от бесплатных и быстрых, но с ошибками (Edge TTS), до платных и высококачественных (ElevenLabs, Google AI Studio).
- **Клонирование голоса:** Обсуждалась возможность клонирования голоса по 2-3 секундам речи с помощью open-source и проприетарных моделей, многие из которых имеют защиту от несанкционированного копирования.
- **Проблема задержки (лага):** В многокомпонентных системах (STT -> LLM -> TTS) возникает задержка до 3-4 секунд, что неприемлемо для телефонии. Стриминг помогает, но архитектура нестабильна, особенно когда пользователь перебивает систему.

Тестирование и демонстрация голосовых ассистентов

- **Edge TTS:** Продемонстрирован бесплатный сервис от Microsoft, который успешно озвучил фразы с числительными.
- **ElevenLabs:** Показан как платный сервис, генерирующий “живые” дикторские голоса с более естественными эмоциями.
- **Тестирование стилей:** Участники экспериментировали с генерацией речи, используя разные стили: дикторский, с французским акцентом и даже добавляя неречевые звуки (смех).
- **Ассистенты с “характером”:** Обсуждалась задача создания ботов с определенным стилем общения, например, “гопника”. Был протестирован ассистент с “дерзким” характером.
- **Омнимодальные модели:** Продемонстрированы Live-системы, принимающие на вход голос и выдающие на выход голос, что устраняет задержки. Были протестированы разные роли: “космический пират”, речь с немецким акцентом, максимально быстрая речь, речь “пещерного человека” и “литературного гения”.

Применимость и интеграция голосовых роботов

- **Сценарии применения:** Голосовые роботы с задержкой приемлемы, когда клиент знает, что общается с роботом (например, в банке). В активных продажах они вызывают негатив.
- **Модель ИИ с function calling:** Представлена модель, способная вести диалог, искать информацию в реальном времени (например, в CRM) и выполнять фоновые задачи с низкой задержкой. Стоимость составляет 2-5 центов в минуту.
- **Сложности интеграции с телефонией:** Основная проблема — организация дуплексного режима связи (одновременный разговор и слушание). Для её решения предложен пакет `PipeCat`, который создает “трубы” для конвертации аудиопотоков между телефонией (например, Twilio) и языковой моделью.
- **План интеграции:** Первоначальный шаг — не подключать ИИ, а интегрировать Twilio в CRM, чтобы менеджеры могли звонить прямо из системы. Все звонки будут записываться и транскрибироваться для анализа.
- **Использование Twilio:** Для покупки номера в Twilio (стоимость около \$1/мес) требуется пройти проверку. Создание нового номера через Twilio проще, чем подключение существующего через SIP-транк.

Дальнейшие шаги

- [] Интегрировать Twilio для совершения звонков из CRM-системы.

- [] Настроить запись и транскрибацию звонков для анализа.
- [] Создать диалогового бота, который принимает голосовые сообщения и отвечает голосом, настроив его на общение в грубой манере (“гопник”).
- [] Рассмотреть использование пакета `PipeCat` для подключения языковой модели к телефонии в дуплексном режиме.
- [] Купить телефонный номер в Twilio, пройдя необходимую проверку.
- [] [Вставьте еще]

Рекомендации ИИ

ИИ обнаружил следующие вопросы, которые не были решены на встрече или по которым отсутствуют четкие дальнейшие действия; пожалуйста, обратите внимание:

1. Не было принято окончательного решения о выборе конкретных технологий: какой инструмент TTS (Edge TTS, ElevenLabs) использовать, и стоит ли переходить на омнимодальные модели вместо многокомпонентных систем для телефонии.
2. Остались неопределенными конкретные бизнес-сценарии применения голосовых ассистентов, особенно в контексте прямых продаж, а также практическое применение функции клонирования голоса.
3. Не были определены бюджет на платные сервисы (Twilio, `PipeCat`) и ответственные за прохождение верификации в Twilio.
4. Неясно, как будет реализована функция добавления неречевых звуков (например, смеха) в генерируемую речь.