

05-22 Лекция: Архитектура агентных систем и интеграция голосовых технологий (STT/TTS/телефония) с Telegram и YouTube

Дата и время: 2026-05-22 10:18:40

Локация: [Вставить локацию]

Инструктор: [Вставить имя]

Резюме

Лекция в рамках восьмого модуля курса посвящена системной архитектуре агентных решений и практической интеграции голосовых технологий (распознавание, генерация, телефония) в единую программу, а также построению телеграм-бота для обработки аудио в контексте продаж. Инструктор делает промежуточный обзор архитектуры: роль агента (OpenCore/Codex/DLMS), вынесение знаний и задач во внешние компоненты (БД и модуль tasks), необходимость отдельного пользовательского интерфейса, единые подходы к проектной структуре и документации (AgentsMD/CLOD-MD/GED-MD, ToDo/Backlog, README, Hand-off, PRD, принцип «one source of truth», регулярный housekeeping). Практическая часть фокусируется на STT: модели Whisper, сервис Deegram, локальный запуск vs API, экономические и скоростные соображения, безопасность ключей и раздельность окружений, сбор телеграм-бота, который принимает голос, конвертирует, отправляет на распознавание и возвращает транскрипт с резюме. Обсуждаются два подхода к пайплайну: классический «голос → STT → текст → LLM → summary» и мультимодальный «голос → LLM» без отдельного STT (например, через Google Gemini/Flash и OpenRouter), их качество, стоимость и устойчивость к вариативности речи. Отдельно рассматривается интеграция YouTube (субтитры или извлечение аудио), ограничения (403), обходы (Y2Mate), формат результата с фронтматтером (summary) и детализацией транскрипта в Markdown. Показаны организационные и аппаратные аспекты записи и транскрибации (диктофоны, «Plate» для iPhone через MagSafe), планы на TTS, live-модели и телефонию. Присутствуют практические кейсы с предпринимателями (Денис, Юра), намечены тесты и обратная связь.

Ключевые пункты

1. Архитектура системы и проектная дисциплина

- Агент как интерфейс и его ограничения: при усложнении задач требуется вынесение знаний в внешнюю БД, задач — в модуль tasks, добавление UI для управления лидами, звонками, задачами и статусами.
- Документация и единый источник правды: автозагружаемые профили (AgentsMD/CLOD-MD/GED-MD) для контекстуализации, Hand-off как краткий «снимок» проекта, ToDo/Backlog для планирования, README для структуры, PRD как «библия» требований; запрет на дублирование информации, поддержание актуальности, регулярный housekeeping.
- Универсальность методологии: применимо к Codex, OpenCore, Claude, Anti-Gravity и др.; различаться могут только имена файлов автозагрузки.

2. Голосовые функции и телефония

- Мотивация: рост требований приводит к необходимости звонков из CRM, записи и анализа разговоров; голосовые функции (STT/TTS/телефония) — ключевой пазл экосистемы.
- Цель: подключить распознавание, генерацию и прием через телефонию в рамках одной программы; в CRM — кнопка «Звонить», запись разговора, автоматическое summary и метрики (продажи, ошибки, следование скрипту); перспектива — автоматические звонки агентом.

3. STT: модели, сервисы, производительность и безопасность

- Whisper: открытая модель (семейство размеров ~3–6 ГБ), трансформерная архитектура с чанками и влиянием контекста; поддержка многих языков, точность зависит от языка; локальный запуск возможен, но не real-time без ускорений.
- Deepgram и облака: простая регистрация, кредиты (~\$200), низкая стоимость транскрибации; практика сравнения скорости/точности/стоимости; альтернатива дорогим диктофонам — телеграм-бот с почти нулевой эксплуатационной стоимостью.
- Управление проектами и безопасностью: репозитории GitHub и облачная синхронизация, раздельность токенов для разных ботов, вынесение секретов в .env, ограничение доступа по Telegram ID.

4. Пайплайны обработки аудио: STT+LLM vs мультимодальный LLM

- Классический конвейер: «голос → STT → текст → LLM → summary». Проблема: качество summary падает при неточной транскрибации

(быстрая речь, акценты).

- Мультимодальный подход: сразу отправлять аудио в LLM (например, Google Gemini 3.5 Flash/Pro Lite/Flash Lite 3.1) через OpenRouter для одновременного получения транскрипта и summary; потенциально выше устойчивость, проще архитектура, ниже токеноемкость.
- Формат результата: один Markdown с фронтматтером summary сверху и подробным транскриптом ниже; удобно для дальнейшей обработки.

5. Экономика и архитектурный выбор: агентный оркестратор vs независимый бот

- Независимый бот: заранее закодированная логика на Python, прямые вызовы Deepgram или LLM через OpenRouter; минимизация шагов и системных промтов, экономия токенов и снижение задержек.
- Агентный подход: многошаговые вызовы скиллов, системные промты, 3–5 центов на запуск транскрибации; при масштабе затраты растут; доплаты за платформу и внешние сервисы.
- Оценка стоимости инференса аудио: ориентир ~\$0.50 за миллион токенов; единицы центов за минуту речи; демонстрации показали сессии порядка \$0.01.

6. Интеграция с Telegram и YouTube

- Telegram как интерфейс и идентификация: удобный фронт без веб-UI, контроль доступа по user ID, внутренние уведомления, отчеты, взаимодействие с агентами.
- YouTube: если есть субтитры — извлечение; если нет — извлечение аудио и транскрибация; возможны ошибки 403 и блокировки; обход — конвертация видео в MP3 через Y2Mate, последующая обработка ботом.

7. Качество, пост-обработка и практические тесты

- Кросс-языковые тесты (включая эстонский, смешение языков): система работает стабильно, иногда сбой — повторный запуск помогает; мультимодальные модели лучше держат «быстрый говор».
- Пост-обработка LLM: дополнительный этап корректуры поверх «90% хорошей» транскрибации для исправления ошибок, повышение итогового качества.
- Логирование и метрики: статус-уведомления в боте, замер скорости (коэффициент времени), оценка точности по языкам, учет стоимости токенов и производительности.

8. Аппаратные и правовые аспекты записи

- Диктофоны и аксессуары: смартфон, «ручка»-диктофон (Philips и др.), «Plate» для iPhone через MagSafe — считывает вибрации динамика, записывает обе стороны разговора без системных разрешений; актуально в европейских юрисдикциях.
- Правовые ограничения: изучить местные нормы записи звонков; «Plate» помогает обходить технические запреты, не вмешиваясь в ОС.

9. Оркестрация и будущие модули

- Оркестраторы многоагентных систем (например, Paperclip): координация агентов для соцсетей/маркетинга/продаж; возможно краткая демонстрация в будущих модулях.
- Генерация изображений и видео: запланированы модули и кейсы интеграции в общую систему.
- Планы занятий: после STT — TTS, далее live-модели и телефония.

Вопросы

- [Вставить вопрос/неясность]

Задания

- [] Провести «хаускиппинг» документации: удалить устаревшее, сжать большие файлы, выровнять под «one source of truth».
- [] Внедрить автозагружаемый файл контекста (AgentsMD/CLOD-MD/GED-MD) со ссылками на README, ToDo/Backlog, Hand-off, PRD.
- [] Создать Hand-off: текущее состояние, выполненные задачи, план и статус для ускорения старта новых сессий.
- [] Подготовить/актуализировать PRD: цели, требования, развилки, сценарии, нефункциональные требования.
- [] Сформировать ToDo/Backlog: ближайшие/будущие задачи, учесть будущие интеграции (например, «YLAB») в схеме данных.
- [] Спланировать UI: ключевые экраны (лиды, фильтры, статусы звонков, задачи), снизить зависимость от диалога с агентом.
- [] Создать репозиторий на GitHub, вынести секреты в .env; развести токены разных ботов, ограничить доступ по Telegram ID.
- [] Зарегистрироваться в Deergram, сгенерировать тестовый API-ключ с ограниченным сроком, подтвердить кредиты.
- [] Собрать Telegram-бота: прием аудио, конвертация, отправка в Deergram, возврат транскрипта в MD, статус-уведомления, логирование.

- [] Добавить суммаризацию LLM поверх транскрипта; протестировать мультимодальный пайплайн: аудио напрямую в LLM (Gemini/Flash) через OpenRouter, получить транскрипт+summary.
- [] Сравнить качество и скорость: Deepgram+LLM vs мультимодальный LLM на быстрой и акцентированной речи; задокументировать результаты.
- [] Интегрировать обработку YouTube: субтитры или извлечение аудио; добавить fallback через Y2Mate.
- [] Настроить формат Markdown: фронтматтер с полями (дата, участники, тема, итог) + подробный транскрипт; убедиться в стабильности вывода.
- [] Встроить кнопку «Звонить» в CRM: запись разговора, автоматическое summary, метрики; оценить производительность и стоимость на масштабе (10 звонков/день × 100 менеджеров).
- [] Оценить целесообразность Telegram как интерфейса CRM/агентных задач: пользователи, права, типы отчетов.
- [] Подготовить тестовый набор аудио (диктофон, интервью) для валидации обеих схем; провести параллельные тесты на Codex и Anti-Gravity.
- [] Исследовать правовые аспекты записи звонков; протестировать «Plate» для iPhone; подготовить демо с телефонией для следующего урока.